Entrega Técnica fase 2

1. Entregável: Base de Dados Tratada

- **Origem dos dados**
  - Microdados não identificados do Novo CAGED, disponibilizados pelo Ministério do Trabalho, do período entre Agosto de 2025 e Julho de 2026
- **Versão original utilizada**
  - TXT delimitados por ponto e vírgula em UTF-8, obtidos de arquivos compactados.
- **Versão resultante após o tratamento**
  - Arquivo base_tratada.csv, com uma linha por competência: região/UF, seção CNAE, sexo, raça/cor, faixa etária e tipo de movimentação.
- **Principais decisões tomadas durante o processo**
  - Utilização do software R (recomendado pela plataforma de onde os dados foram retirados) para processar um mês por vez. Campos vazios foram convertidos em nulos, códigos foram preservados como texto e idades foram agrupadas em faixas.
- **Justificativas para as transformações realizadas**
  - Controlar o consumo de memória e redução de volume.

2. Entregável: Processo de Tratamento dos Dados

O processo de tratamentos teve o seguinte fluxo:

arquivo compactado -> TXT -> Software R -> seleção e tratamento* → agregação mensal → PostgreSQL/Aiven → dicionários oficiais e view com rótulos.

*O processo de seleção e tratamento dos dados consistiu na aplicação dos planos feitos durante a etapa 1, ou seja, seleção das 17 variáveis, padronização e conversão de dados, conversão de tipos/campos vazios, determinação de faixas etárias e agregação antes da carga.

3. Entregável: Base Armazenada em Banco de Dados

- Estrutura criada;
    - Infraestrutura: PostgreSQL hospedado no Aiven, banco defaultdb, schema caged. O modelo é uma tabela analítica agregada, acompanhada de metadados, auditoria e dicionários. Os microdados originais ficam fora do banco hospedado.

- Principais entidades/tabelas utilizadas;

Campo	**Tipo PostgreSQL**	**Finalidade**
id	BIGINT	Chave primária da linha agregada
competencia	DATE	Primeiro dia do mês de movimentação
regiao_codigo	TEXT	Código regional preservado
uf_codigo	TEXT	Código da UF preservado
setor_cnae	TEXT	Seção CNAE 2.0
sexo_codigo	TEXT	Código de sexo preservado
racacor_codigo	TEXT	Código de raça/cor preservado
faixa_etaria	TEXT	Faixa criada a partir da idade
tipo_movimentacao_codigo	TEXT	Código de movimentação preservado
tipo_fluxo	TEXT	Admissão, desligamento ou não identificado
total_registros	BIGINT	Movimentações representadas no grupo
admissoes	BIGINT	Contagem com saldo +1
desligamentos	BIGINT	Contagem com saldo -1
saldo	BIGINT	Admissões menos desligamentos
saldo_invalido	BIGINT	Contagem de saldos fora de -1/+1 ou nulos
soma_salarios_validos	NUMERIC(38,6)	Soma de salários usados na média
quantidade_salarios_validos	BIGINT	Denominador para recompor a média
remuneracao_media	NUMERIC	Média salarial do grupo